

Laporan praktikum 1: Scraping dan EDA

Nama : Hilal Tsabitul Azmi Arba'i

Kelas : N

NRP : 5054251008

Deskripsi Dataset:

Dataset diperoleh dari proses web scraping dari halaman Wikipedia yang berisi daftar film Amerika Serikat pada rentang tahun 2000 hingga 2025. Proses scraping dilakukan menggunakan library requests, BeautifulSoup, dan pandas.read_html() untuk mengambil tabel film pada setiap halaman tahun. Hasil scraping menghasilkan sebanyak 6076 baris data dengan 9 atribut awal, yaitu

Atribut	Tipe Data	Kategori
Opening	object	ordinal
Opening.1	float64	numerik diskrit
Title	object	nominal
Production company	object	nominal
Cast and crew	object	nominal
Ref.	object	nominal
Year	int64	numerik diskrit
Unnamed: 5	float64	-
Production Company	object	nominal

Pembersihan Data:

1. ditemukan kolom yang duplikat

- a. Production Company
- b. Production company

keduanya merupakan atribut yang sama namun memiliki penamaan yang berbeda.

Kemungkinan besar masalah ini disebabkan oleh variasi penulisan tabel di wikipedia pada tahun tertentu. Langkah yang saya ambil yakni menggabungkan kedua kolom menjadi satu atribut menggunakan fungsi fillna()

2. Kolom Ref.

Kolom tersebut berisi nomor referensi wikipedia sehingga tidak memberikan nilai analitis. oleh karena itu, kolom tersebut saya hapus

3. kolom kosong

kolom Unnamed: 5 memiliki 0 non-null values yang artinya kolom tersebut benar benar kosong. Oleh karena itu, kolom tersebut saya hapus

4. Dataset Cleaning

Setelah saya bersihkan, sekarang atributnya menjadi 6 yaitu;

Opening, Opening.1, Title, Production company, Cast and crew, dan Year.

Analisis Missing Value:

1. Nilai yang hilang pada tiap atribut

```
: Opening      3
  Opening.1    81
  Title        82
  Production company 84
  Cast and crew 84
  Year         0
```

2. Persentase missing value

```
Opening      0.049375
Opening.1    1.333114
Title        1.349572
Production company 1.382488
Cast and crew 1.382488
Year         0.000000
```

secara keseluruhan jumlah missing value sangat kecil, seluruhnya berada di bawah 2% dari total data. Hal ini menunjukkan bahwa kualitas dataset hasil scraping tergolong baik dan tidak memerlukan penanganan khusus yang kompleks.

Statistik Deskriptif

1. Atribut Opening.1:

	Opening.1	Year
count	5995.000000	6076.000000
mean	15.929441	2012.802502
std	8.484506	7.559139
min	1.000000	2000.000000
25%	9.000000	2007.000000
50%	16.000000	2013.000000
75%	23.000000	2019.000000
max	31.000000	2025.000000

Rata-rata tanggal rilis berada pada pertengahan bulan (hari ke-16). Hal ini menunjukkan bahwa distribusi tanggal rilis film relatif merata sepanjang bulan.

2. Atribut Year:

	Opening.1	Year
count	5995.000000	6076.000000
mean	15.929441	2012.802502
std	8.484506	7.559139
min	1.000000	2000.000000
25%	9.000000	2007.000000
50%	16.000000	2013.000000
75%	23.000000	2019.000000
max	31.000000	2025.000000

Dataset memiliki cakupan waktu yang luas dari tahun 2000 hingga 2025. Nilai median sebesar 2013 menunjukkan bahwa distribusi film cukup seimbang antara periode awal dan akhir dataset.

Analisis Data Kategorikal

1. Bulan rilis film:

```

frkuensi data kategorikal: Opening
O C T O B E R      609
D E C E M B E R    581
S E P T E M B E R  568
A U G U S T        560
M A R C H          530
A P R I L          520
N O V E M B E R    517
J U N E            475
M A Y              451
F E B R U A R Y    443
J U L Y            433
J A N U A R Y      369
N O V E M B E      16
27                1
.. ..

```

Film paling banyak dirilis pada bulan Oktober. Selain itu, September dan Desember juga memiliki jumlah rilis yang tinggi. Hal ini menunjukkan adanya kecenderungan industri film merilis film pada periode tertentu dalam satu tahun.

2. Production company terbanyak

```

frekuensi data kategorikal: Production company
Lionsgate          104
Netflix            98
Fox Searchlight Pictures 91
Sony Pictures Classics 80
20th Century Fox    79

```


Lionsgate menjadi perusahaan produksi yang paling sering muncul dalam dataset. Selain studio film tradisional, Netflix juga termasuk salah satu perusahaan dengan jumlah produksi film yang sangat tinggi.

Feature Engineering

1. Panjang Judul Film: menghitung panjang kata dalam judul film
2. Panjang Informasi cast: menghitung panjang teks informasi pemeran dan kru
3. Panjang nama company: menghitung panjang teks nama perusahaan produksi

Visualisasi dan Interpretasi

1. Distribusi tahun rilis film, yakni:



histogram menunjukkan distribusi jumlah rilis film dari tahun 2000-2025. Jumlah film relatif konsisten pada seluruh rentang tahun 2000-2025. Terlihat peningkatan jumlah film pada beberapa tahun terbaru, terutama mendekati tahun 2025.

2. 10 Production Company Terbanyak

Industri perfilman Amerika didominasi oleh sejumlah kecil perusahaan produksi besar yang secara konsisten menghasilkan banyak film selama periode pengamatan.

3. Distribusi Panjang Judul Film

Distribusi bersifat positively skewed (miring ke kanan). Mayoritas film memiliki judul yang pendek, sekitar 2-4 kata. Hanya sedikit film yang memiliki judul sangat panjang hingga lebih dari 10 kata. Selain itu, nilai mean berada di sebelah kanan median yang semakin memperkuat indikasi distribusi tidak simetris.

4. Scatter Plot Year vs Panjang Judul

Tidak terlihat pola hubungan yang kuat antara tahun rilis film dengan panjang judulnya. Judul panjang maupun pendek dapat ditemukan pada hampir seluruh rentang tahun.

5. Heatmap korelasi

Sebagian besar korelasi berada di dekat nol yang menunjukkan hubungan linear yang lemah antar variabel.

Kesimpulan

Pada praktikum ini telah dilakukan proses scraping data film Amerika Serikat dari Wikipedia periode 2000-2025. Hasil scraping menghasilkan 6076 baris data, melebihi syarat minimal praktikum. Proses pembersihan data berhasil mengatasi atribut yang kosong dan atribut duplikat sehingga diperoleh dataset yang lebih konsisten. Analisis menunjukkan bahwa jumlah missing value sangat rendah (<2%), menandakan kualitas data yang baik. Visualisasi mengungkap beberapa temuan penting, seperti dominasi bulan Oktober dalam jadwal rilis film, dominasi perusahaan produksi besar seperti Lionsgate dan Netflix, serta distribusi panjang judul film yang cenderung miring ke kanan. Selain itu, analisis korelasi menunjukkan bahwa sebagian besar variabel numerik memiliki hubungan yang lemah sehingga karakteristik film dalam dataset relatif beragam.