LAPORAN PRAKTIKUM 3

Classification dengan Ensemble Method dan Class Imbalance

Credit Card Fraud Detection

Nama	Hilal Tsabitul Azmi Arbai
NRP	5054251008
Kelas	N

2026

1. Pendahuluan

Klasifikasi transaksi penipuan merupakan permasalahan klasifikasi biner dengan distribusi kelas yang sangat tidak seimbang. Pada dataset Credit Card Fraud Detection, transaksi normal jauh lebih dominan dibandingkan transaksi fraud. Kondisi ini dapat menyebabkan model lebih berorientasi pada kelas mayoritas dan menghasilkan accuracy tinggi meskipun masih melewatkan transaksi fraud.

Praktikum ini menerapkan Random Forest sebagai ensemble method dan membandingkan tiga pendekatan: model baseline tanpa penanganan imbalance, oversampling menggunakan Synthetic Minority Over-sampling Technique (SMOTE), dan cost-sensitive learning menggunakan class weight. Evaluasi utama difokuskan pada kelas fraud menggunakan precision, recall, F1-score, ROC-AUC, PR-AUC, dan confusion matrix.

1.1 Tujuan

- Mengidentifikasi tingkat class imbalance pada dataset transaksi kartu kredit.
- Membangun model Random Forest sebagai model ensemble klasifikasi.
- Menerapkan SMOTE dan class weight untuk menangani ketidakseimbangan kelas.
- Membandingkan performa model menggunakan metrik yang relevan untuk kelas minoritas.

2. Dataset dan Pemeriksaan Awal

Dataset terdiri atas 284.807 observasi dan 31 kolom. Sebanyak 30 kolom digunakan sebagai fitur, sedangkan kolom Class digunakan sebagai target. Nilai 0 menyatakan transaksi normal dan nilai 1 menyatakan transaksi fraud. Seluruh kolom bertipe numerik, yaitu 30 kolom float64 dan satu kolom int64. Pemeriksaan data menunjukkan tidak terdapat missing value.

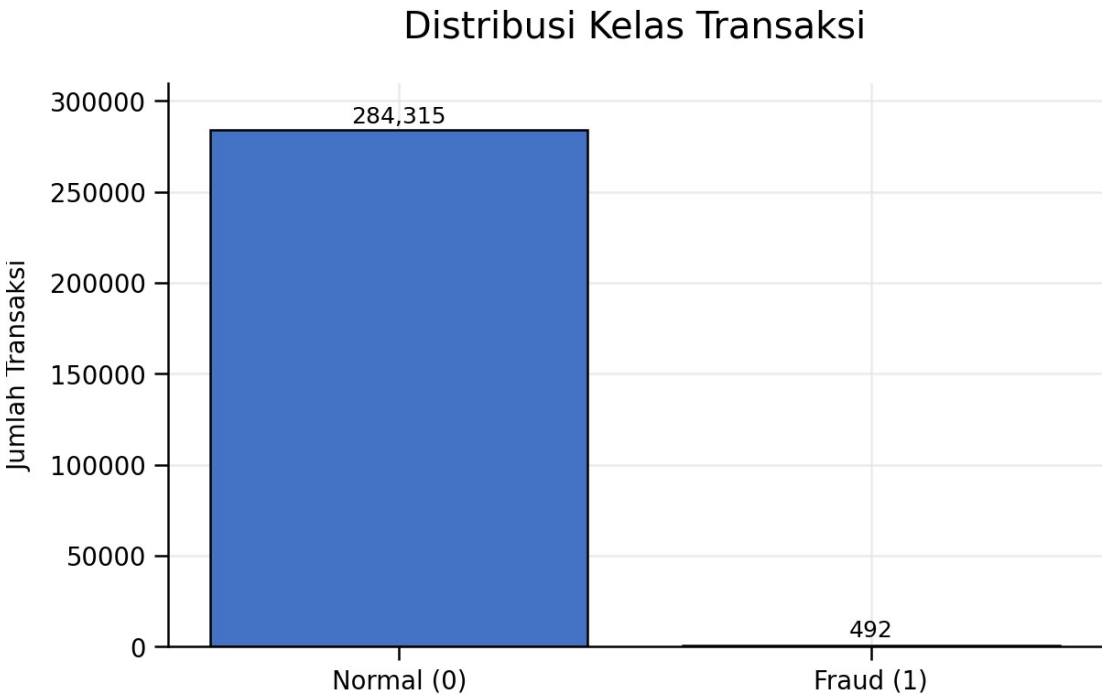
Komponen	Hasil
Jumlah observasi	284.807
Jumlah kolom	31
Fitur	Time, V1-V28, Amount
Target	Class
Missing value	0
Duplikat	1.081 baris

Terdapat 1.081 baris duplikat. Data duplikat tidak langsung dihapus karena transaksi dengan nilai fitur identik belum tentu merupakan kesalahan pencatatan. Selain itu, penghapusan dilakukan secara hati-hati agar tidak mengurangi sampel kelas fraud yang jumlahnya sangat terbatas.

2.1 Distribusi Kelas

Kelas	Jumlah	Persentase
Normal (0)	284.315	99,8273%

Kelas	Jumlah	Persentase
Fraud (1)	492	0,1727%



Gambar 1. Distribusi kelas transaksi pada dataset awal.

Kelas fraud hanya mencakup 0,1727% dari seluruh transaksi. Ketimpangan ini menunjukkan bahwa accuracy tidak dapat digunakan sebagai satu-satunya dasar penilaian. Model yang selalu memprediksi kelas normal tetap dapat memperoleh accuracy sekitar 99,83%, tetapi tidak mendeteksi satu pun fraud.

3. Metodologi

3.1 Pembagian dan Standardisasi Data

Fitur dan target dipisahkan terlebih dahulu, kemudian dataset dibagi menjadi data latih dan data uji dengan perbandingan 80:20. Parameter stratify=y digunakan agar proporsi kelas pada kedua bagian tetap mendekati distribusi awal. Random state ditetapkan sebesar 42 untuk menjaga reproduktibilitas eksperimen.

StandardScaler dipelajari hanya dari data latih, kemudian digunakan untuk mentransformasikan data latih dan data uji. Langkah ini mencegah informasi dari data uji masuk ke proses pelatihan. Standardisasi juga mendukung proses SMOTE yang membentuk sampel sintetis berdasarkan kedekatan antarobservasi.

3.2 Skenario Model

Skenario	Konfigurasi
Baseline	Random Forest, 100 pohon, tanpa penanganan imbalance
SMOTE	SMOTE sampling_strategy=0,1 pada data latih, lalu Random Forest 100 pohon

Skenario	Konfigurasi
Class Weight	Random Forest 100 pohon dengan class_weight="balanced"

SMOTE hanya diterapkan pada data latih. Jumlah fraud pada data latih meningkat dari 394 menjadi 22.745, sedangkan jumlah transaksi normal tetap 227.451. Data uji tidak di-resampling agar evaluasi tetap merepresentasikan distribusi kelas asli.

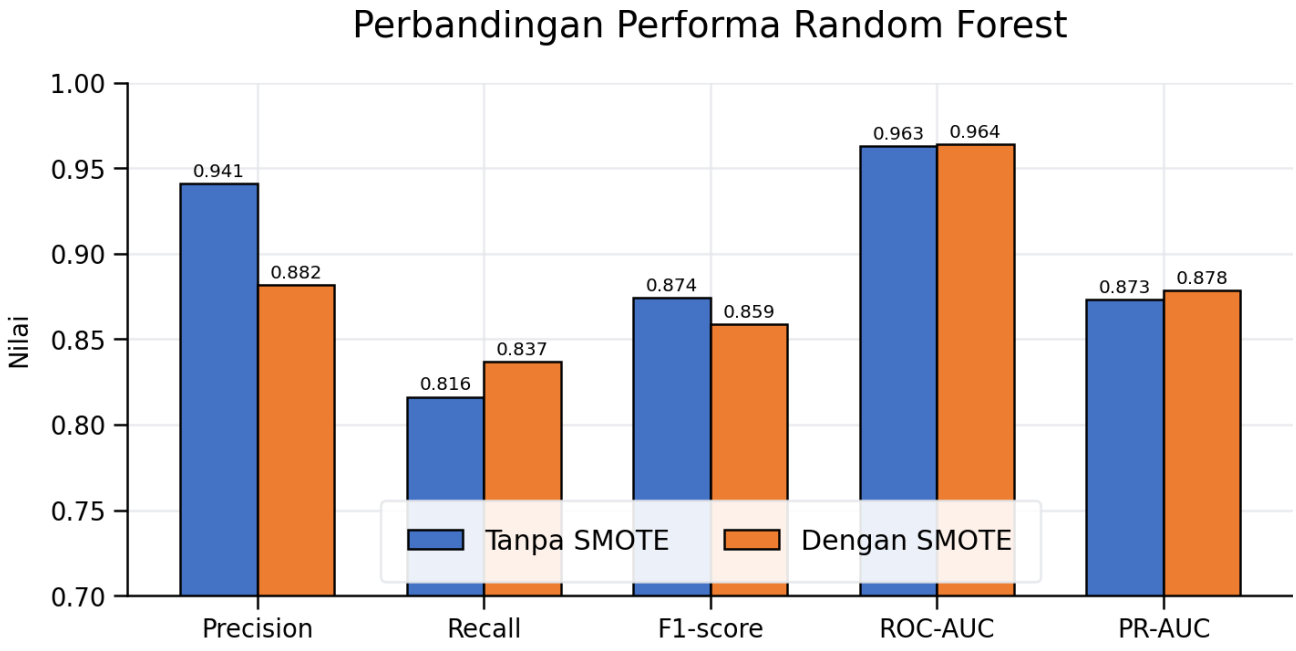
3.3 Metrik Evaluasi

Precision mengukur ketepatan prediksi fraud, sedangkan recall mengukur proporsi fraud aktual yang berhasil dideteksi. F1-score merangkum keseimbangan precision dan recall. ROC-AUC menilai kemampuan pemisahan kelas pada berbagai threshold, sedangkan PR-AUC menekankan hubungan precision-recall pada kelas positif yang langka. Confusion matrix digunakan untuk melihat true positive, false positive, false negative, dan true negative secara langsung.

4. Hasil dan Pembahasan

4.1 Perbandingan Model Utama

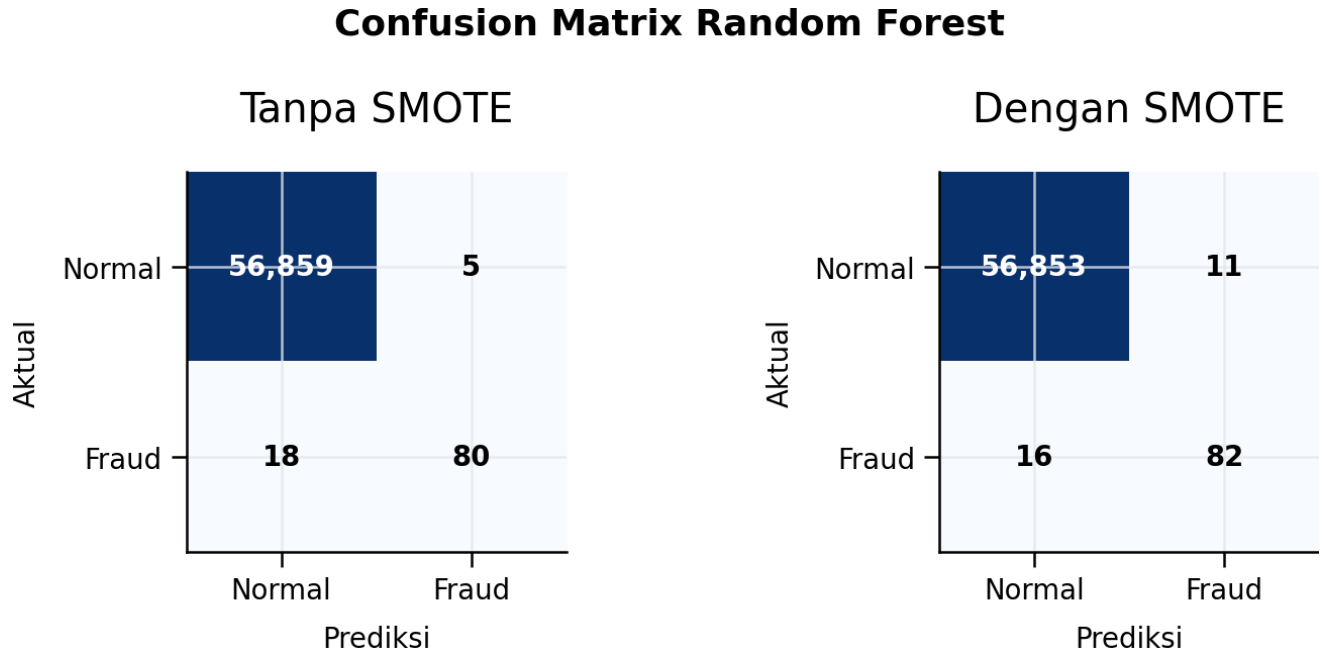
Model	Precision	Recall	F1	ROC-AUC	PR-AUC	FP	FN	TP
RF tanpa SMOTE	0,9412	0,8163	0,8743	0,9630	0,8734	5	18	80
RF + SMOTE	0,8817	0,8367	0,8586	0,9642	0,8784	11	16	82
RF + Class Weight	0,9605	0,7449	0,8391	0,9529	0,8539	3	25	73



Gambar 2. Perbandingan metrik Random Forest tanpa dan dengan SMOTE.

Model baseline menghasilkan precision tertinggi kedua sebesar 0,9412 dan F1-score tertinggi sebesar 0,8743. Model dengan SMOTE meningkatkan recall dari 0,8163 menjadi 0,8367 serta meningkatkan true positive dari 80 menjadi 82. Pada saat yang sama, false negative turun dari 18 menjadi 16. Peningkatan sensitivitas tersebut disertai penurunan precision menjadi 0,8817 karena false positive meningkat dari 5 menjadi 11.

Model class weight memiliki precision tertinggi sebesar 0,9605 dan false positive terendah sebanyak 3. Namun, recall turun menjadi 0,7449 dan false negative meningkat menjadi 25. Dengan demikian, pendekatan ini paling konservatif dalam memberikan label fraud, tetapi melewatkan lebih banyak fraud aktual.

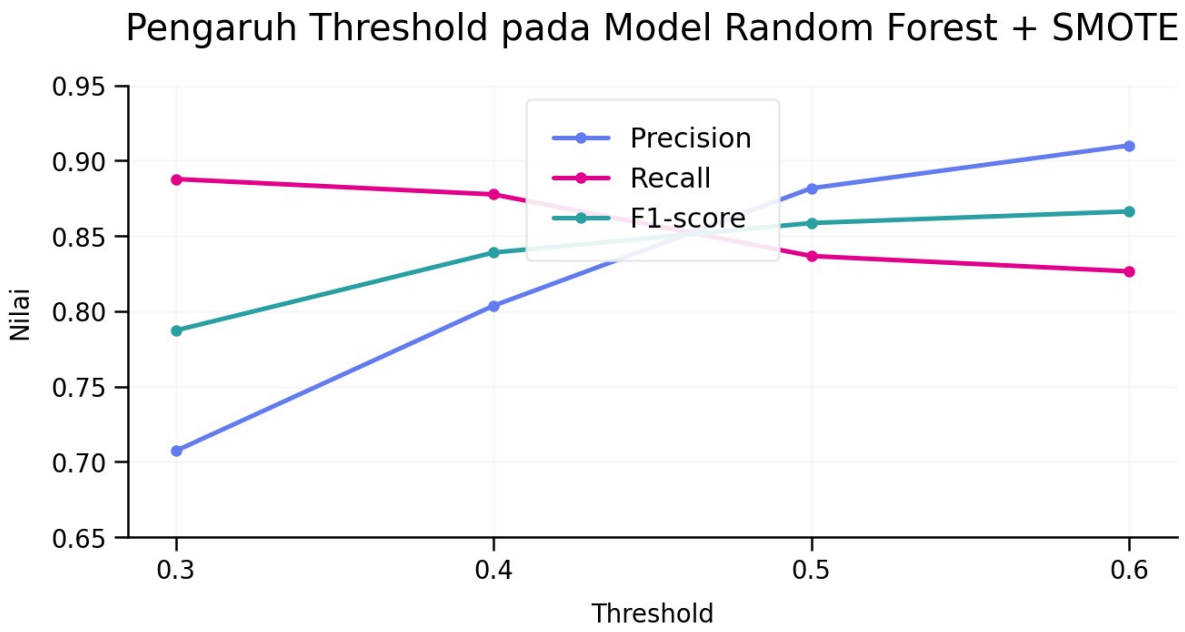


Gambar 3. Confusion matrix model baseline dan model dengan SMOTE.

Confusion matrix memperlihatkan trade-off yang jelas. SMOTE berhasil mendeteksi dua fraud tambahan, tetapi menghasilkan enam false alarm tambahan. Dalam konteks deteksi fraud, pilihan model harus mempertimbangkan biaya fraud yang lolos dibandingkan biaya pemeriksaan transaksi normal yang salah ditandai.

4.2 Analisis Threshold

Threshold	Precision	Recall	F1-score	FP	FN	TP
0,3	0,7073	0,8878	0,7873	36	11	87
0,4	0,8037	0,8776	0,8390	21	12	86
0,5	0,8817	0,8367	0,8586	11	16	82
0,6	0,9101	0,8265	0,8663	8	17	81



Gambar 4. Pengaruh perubahan threshold pada model Random Forest dengan SMOTE.

Penurunan threshold dari 0,5 menjadi 0,3 meningkatkan recall dari 0,8367 menjadi 0,8878 dan true positive dari 82 menjadi 87, tetapi precision turun menjadi 0,7073 dan false positive naik menjadi 36. Sebaliknya, threshold 0,6 menghasilkan precision dan F1-score yang lebih tinggi daripada threshold 0,5, tetapi recall sedikit lebih rendah. Analisis ini menunjukkan bahwa threshold dapat disesuaikan dengan prioritas operasional, bukan hanya menggunakan nilai default 0,5.

4.3 Mengapa Accuracy Tidak Cukup

Kedua model utama memperoleh accuracy sekitar 99,95%. Nilai tersebut tampak sangat tinggi, tetapi model masih melewatkan 18 fraud pada baseline dan 16 fraud pada model SMOTE. Karena kelas normal mendominasi 99,8273% data, accuracy terutama mencerminkan keberhasilan mendeteksi transaksi normal. Oleh sebab itu, keputusan model lebih tepat didasarkan pada recall, precision, F1-score, PR-AUC, dan jumlah false negative.

5. Kesimpulan

Dataset Credit Card Fraud Detection memiliki class imbalance yang sangat tinggi, yaitu 284.315 transaksi normal dan 492 transaksi fraud. Random Forest tanpa SMOTE memberikan F1-score tertinggi sebesar 0,8743 dan hanya menghasilkan lima false positive. Random Forest dengan SMOTE memberikan recall tertinggi sebesar 0,8367, meningkatkan true positive dari 80 menjadi 82, serta mengurangi false negative dari 18 menjadi 16.

Tidak ada satu pendekatan yang unggul pada seluruh metrik. SMOTE lebih sesuai jika prioritas utama adalah mengurangi fraud yang tidak terdeteksi, sedangkan model baseline lebih sesuai apabila keseimbangan precision-recall dan pengendalian false alarm menjadi pertimbangan utama. Model class weight menghasilkan precision tinggi tetapi recall paling rendah, sehingga kurang sesuai apabila biaya false negative dianggap besar.

Secara keseluruhan, penanganan class imbalance harus dinilai berdasarkan tujuan sistem dan konsekuensi kesalahan prediksi. Untuk konteks deteksi fraud yang memprioritaskan penurunan false negative, Random Forest dengan SMOTE dapat dipilih,

dengan kemungkinan penyesuaian threshold setelah mempertimbangkan toleransi terhadap false positive.

6. Catatan Implementasi

- SMOTE diterapkan hanya pada data latih untuk mencegah data leakage.
- Data uji mempertahankan distribusi asli agar evaluasi mencerminkan kondisi nyata.
- Random state 42 digunakan pada pembagian data, SMOTE, dan model agar hasil dapat direproduksi.
- Pemilihan model akhir tidak hanya mengacu pada accuracy, tetapi pada performa kelas fraud dan dampak FP/FN.