

LAPORAN PRAKTIKUM 2

PRAPROSES DATA

House Prices - Advanced Regression Techniques

Nama	Hilal Tsabitul Azmi Arba'i
NRP	5054251008
Dataset	train.csv - House Prices
Keluaran	Dataset bersih dan tereduksi

2026

1. Pendahuluan

Praproses data merupakan tahap penting sebelum analisis maupun pemodelan machine learning karena kualitas data masukan akan memengaruhi kualitas hasil yang diperoleh. Pada praktikum ini digunakan dataset House Prices - Advanced Regression Techniques yang memuat karakteristik rumah dan harga jualnya. Proses praproses mencakup identifikasi struktur data, penanganan nilai hilang, penanganan outlier, transformasi fitur, analisis korelasi, serta reduksi dimensi menggunakan Principal Component Analysis (PCA).

Tujuan praktikum adalah menghasilkan dataset yang bersih, seluruh fiturnya dapat diproses secara numerik, bebas nilai hilang, dan memiliki dimensi yang lebih ringkas tanpa kehilangan sebagian besar variasi informasi. Kolom Id dipertahankan sebagai identifier, sedangkan SalePrice diperlakukan sebagai variabel target dan tidak dimasukkan ke transformasi fitur maupun PCA.

2. Pemahaman Dataset

Dataset awal terdiri atas 1.460 baris dan 81 kolom. Pemeriksaan tipe data menunjukkan 35 kolom bertipe integer, 3 kolom bertipe float, dan 43 kolom bertipe object. Setelah Id dan SalePrice dikeluarkan dari kumpulan prediktor, terdapat 36 fitur numerik dan 43 fitur kategoris. Pemeriksaan awal juga menunjukkan tidak terdapat baris duplikat.


Aspek	Hasil pemeriksaan awal
Ukuran dataset	1.460 baris x 81 kolom
Fitur numerik	36 fitur
Fitur kategoris	43 fitur
Identifier	Id
Target	SalePrice
Baris duplikat	0

Pemisahan identifier, target, dan fitur dilakukan untuk menghindari penggunaan Id sebagai informasi prediktif serta mencegah kebocoran target. SalePrice hanya dikembalikan pada tahap penyusunan dataset akhir.

3. Pembersihan Data

3.1 Analisis Nilai Hilang

Pemeriksaan nilai hilang dilakukan dengan menghitung jumlah dan persentase missing value pada setiap atribut. Ditemukan 19 atribut yang memiliki nilai hilang. Lima atribut memiliki proporsi nilai hilang lebih dari 50%, yaitu PoolQC sebesar 99,52%, MiscFeature sebesar 96,30%, Alley sebesar 93,77%, Fence sebesar 80,75%, dan MasVnrType sebesar 59,73%. Sesuai ketentuan praktikum, kelima atribut tersebut dihapus sehingga ukuran data berubah dari 81 menjadi 76 kolom.



Gambar 1. Persentase missing value pada atribut yang memiliki data kosong.

Atribut	Jumlah missing	Persentase
PoolQC	1.453	99,52%
MiscFeature	1.406	96,30%
Alley	1.369	93,77%
Fence	1.179	80,75%
MasVnrType	872	59,73%

3.2 Imputasi dan Konsistensi Data


Nilai hilang yang tersisa ditangani berdasarkan tipe data. Fitur numerik diimputasi menggunakan median karena median lebih tahan terhadap nilai ekstrem. Fitur kategoris diimputasi menggunakan modus agar nilai yang digunakan mewakili kategori yang paling sering muncul. Setelah imputasi, seluruh 76 kolom memiliki 1.460 nilai non-null. Pemeriksaan ulang juga menunjukkan jumlah duplikat tetap nol.

Pendekatan imputasi ini diterapkan secara umum. Pada pengembangan lanjutan, interpretasi semantik setiap atribut dapat diperiksa karena pada beberapa atribut rumah, nilai kosong dapat menggambarkan tidak tersedianya fasilitas dan bukan sekadar data yang tidak tercatat.

4. Deteksi dan Penanganan Outlier

Deteksi outlier difokuskan pada enam atribut numerik yang mewakili luas lahan, luas bangunan, luas ruang bawah tanah, luas lantai pertama, luas garasi, dan tahun pembangunan. Boxplot digunakan untuk melihat penyebaran data, sedangkan aturan Interquartile Range (IQR) digunakan untuk menentukan batas bawah dan batas atas. Sebuah nilai dinyatakan ekstrem secara statistik jika berada di bawah $Q1 - 1,5 \text{ IQR}$ atau di atas $Q3 + 1,5 \text{ IQR}$.


```
plt.tight_layout()
plt.show()
```



Gambar 2. Boxplot enam atribut numerik sebelum penanganan outlier.

Atribut	Batas bawah	Batas atas	Jumlah outlier
LotArea	1.481,50	17.673,50	69
GrLivArea	158,63	2.747,63	31
TotalBsmtSF	42,00	2.052,00	61
1stFlrSF	118,13	2.155,13	20
GarageArea	-27,75	938,25	21
YearBuilt	1.885,00	2.069,00	7


Outlier ditangani menggunakan IQR capping. Nilai di luar batas disesuaikan ke batas terdekat, bukan menghapus seluruh baris. Keputusan ini menjaga jumlah observasi tetap 1.460 dan mempertahankan informasi lain dari rumah yang memiliki nilai ekstrem hanya pada satu atribut. Setelah capping, boxplot menunjukkan nilai pada keenam atribut berada dalam rentang batas IQR yang digunakan.



Gambar 3. Boxplot enam atribut numerik setelah IQR capping.

5. Analisis Korelasi dan Seleksi Fitur

Analisis korelasi Pearson dilakukan pada fitur numerik setelah Id dan SalePrice dipisahkan. Heatmap menampilkan keterkaitan antara SalePrice dan atribut numerik terpilih. Pada visualisasi, korelasi tertinggi terhadap SalePrice terlihat pada OverallQual sebesar 0,79, diikuti GrLivArea sebesar 0,71. Korelasi antar fitur yang cukup kuat juga terlihat, misalnya GarageCars dengan GarageArea sebesar 0,89, serta GrLivArea dengan TotRmsAbvGrd sebesar 0,84.



Gambar 4. Heatmap korelasi atribut numerik terpilih.

Untuk mendeteksi redundansi yang sangat kuat, digunakan ambang korelasi absolut lebih besar dari 0,90. Pemeriksaan dilakukan menggunakan matriks korelasi segitiga atas agar pasangan yang sama tidak dihitung dua kali. Tidak ditemukan pasangan fitur numerik yang melampaui ambang tersebut. Oleh karena itu, tidak ada fitur yang dihapus pada tahap korelasi dan dimensi fitur tetap 1.460 x 74. Keputusan ini menghindari penghilangan informasi tanpa dasar yang memenuhi kriteria.

6. Transformasi Data

6.1 Standardisasi Fitur Numerik

Sebanyak 36 fitur numerik distandarisasi menggunakan StandardScaler. Hasil pemeriksaan menunjukkan rata-rata fitur numerik berada sangat dekat dengan 0 dan simpangan baku berada sekitar 1,00034. Perbedaan kecil dari tepat 1 muncul karena ringkasan pandas menggunakan definisi simpangan baku sampel. Standardisasi diperlukan karena PCA sensitif terhadap skala, sehingga fitur dengan rentang besar tidak mendominasi pembentukan komponen utama.

6.2 One-Hot Encoding Fitur Kategoris


Sebanyak 38 fitur kategoris diubah menggunakan OneHotEncoder dengan `handle_unknown="ignore"`. Setelah standardisasi dan encoding, dimensi fitur meningkat dari 74 menjadi 271 kolom. Peningkatan ini terjadi karena setiap kategori direpresentasikan sebagai kolom indikator tersendiri. Validasi hasil menunjukkan tidak terdapat missing value dan seluruh 271 kolom hasil transformasi bertipe numerik.

Tahap	Jumlah baris	Jumlah fitur	Missing	Non-numerik
Sebelum encoding	1.460	74	0	38
Setelah encoding	1.460	271	0	0

7. Reduksi Dimensi dengan PCA

PCA diterapkan pada 271 fitur hasil standardisasi dan one-hot encoding. Parameter `n_components=0.95` digunakan agar komponen yang dipertahankan menjelaskan sedikitnya 95% variasi kumulatif. Hasilnya, 271 fitur dapat direduksi menjadi 73 komponen utama dengan total explained variance sebesar 0,951126 atau sekitar 95,11%.

```
t.title("Cumulative Explained Variance PCA")
t.legend()
t.grid(alpha=0.3)
t.tight_layout()
t.show()
```



Gambar 5. Kurva cumulative explained variance PCA dengan ambang 95%.

Reduksi dari 271 menjadi 73 komponen berarti jumlah fitur berkurang sebanyak 198 kolom, atau sekitar 73,06%, sementara lebih dari 95% variasi total tetap dipertahankan. Hasil ini menunjukkan PCA mampu merangkum informasi data hasil transformasi ke representasi yang jauh lebih ringkas.

8. Ringkasan Dataset Akhir

Dataset akhir dibentuk dengan menggabungkan Id, 73 komponen utama PCA, dan SalePrice. Dataset memiliki 1.460 baris dan 75 kolom. Sebanyak 73 kolom komponen bertipe float64, sedangkan Id dan SalePrice bertipe int64. Validasi akhir menunjukkan tidak terdapat missing value maupun data duplikat, dan file CSV berhasil dibaca ulang dengan ukuran yang sama.

Informasi	Dataset awal	Setelah pembersihan	Dataset akhir
Jumlah baris	1.460	1.460	1.460
Jumlah kolom	81	76	75
Jumlah fitur pemodelan	79	74	73 komponen
Missing value	Ada pada 19 atribut	0	0
Duplikat	0	0	0
Fitur kategoris	43	38	0

Struktur akhir berupa Id + PC1 sampai PC73 + SalePrice. Dengan struktur tersebut, identifier dan target tetap tersedia, sementara fitur prediktor sudah numerik, bebas nilai hilang, dan memiliki dimensi yang lebih kecil.

9. Kesimpulan

Seluruh tahapan praproses berhasil diterapkan pada dataset House Prices. Lima atribut dengan nilai hilang lebih dari 50% dihapus, sementara missing value yang tersisa diimputasi menggunakan median untuk numerik dan modus untuk kategoris. Outlier pada enam atribut numerik ditangani menggunakan IQR capping sehingga jumlah observasi tetap terjaga. Analisis korelasi dengan ambang absolut 0,90 tidak menemukan pasangan fitur yang perlu dihapus.

Transformasi data menghasilkan 271 fitur numerik melalui standardisasi dan one-hot encoding. PCA kemudian mereduksi fitur tersebut menjadi 73 komponen utama dengan cumulative explained variance sebesar 95,11%. Dataset akhir berukuran 1.460 x 75, tidak memiliki missing value maupun duplikat, dan telah siap digunakan untuk analisis atau pemodelan machine learning berikutnya.

10. Catatan Keterbatasan

Imputasi dilakukan berdasarkan tipe data secara umum dan penanganan outlier hanya diterapkan pada enam atribut numerik terpilih. Analisis lanjutan dapat mempertimbangkan makna domain dari setiap nilai kosong, mengevaluasi outlier pada fitur numerik lainnya, serta menyimpan objek preprocessor dan PCA agar transformasi yang sama dapat diterapkan secara konsisten pada data baru.